




Week 4 Assignment: Statistics, Data Visualization & Exploratory Data Analysis

Task 1: Statistical Analysis – Mean, Median & Mode

EMP ID	NAME	DEPARTMENT	SALARY	STATUS			
103	AMIT VERMA	IT	75000	HIGH	58600	=average(d2:d6)	mean
101	AYUSH GUPTA	IT	65000	HIGH	58000	=median(d2:d6)	median
105	SNEHA VERMA	IT	58000	LOW	50000	=mode.sngl(d2:d7)	mode
104	PRIYA SINGH	MARKETING	50000	LOW			
102	RAHUL SHARMA	HR	45000	LOW			
106	SOMYA TYAGI	IT	50000	LOW			





The screenshot shows an Excel spreadsheet with the following data and formulas:

	A	B	C	D	E	F	G	H	I	J	K
	EMP ID	NAME	DEPARTMENT	SALARY	STATUS						
2	103	AMIT VERMA	IT	75000	HIGH	58600		mean			
3	101	AYUSH GUPTA	IT	65000	HIGH	58000		median			
4	105	SNEHA VERMA	IT	58000	LOW	=MODE.SNGL(D2:D7)		mode			
5	104	PRIYA SINGH	MARKETING	50000	LOW						
6	102	RAHUL SHARMA	HR	45000	LOW						
7	106	somya tyagi	IT	50000	LOW						

The formula bar shows: `=MODE.SNGL(D2:D7)`

TASK 1 explanation

Mean (औसत सैलरी): फॉर्मूला: `=AVERAGE(D2:D7)` आसान समझ: इसका मतलब कंपनी के सभी कर्मचारियों की कुल सैलरी का औसत (Average) निकालना है। कंप्यूटर ने सभी सैलरी को जोड़कर कर्मचारियों की कुल संख्या से भाग दिया, जिससे हमें पता चला कि एक आम कर्मचारी को औसतन 57,600 INR वेतन मिल रहा है।

Median (मधिका सैलरी): फॉर्मूला: `=MEDIAN(D2:D7)` आसान समझ: इसका मतलब पूरी सैलरी लिस्ट को छोटे से बड़े क्रम में सजाने के बाद बिल्कुल बीच में आने वाली सैलरी का पता लगाना है। इससे हमें यह जानने में मदद मिली कि कंपनी के ठीक आधे कर्मचारियों की सैलरी 54,000 INR से कम है और बाकी आधे कर्मचारियों की सैलरी इससे ज़्यादा है।

Mode (बहुलक सैलरी): फॉर्मूला: `=MODE.SNGL(D2:D7)` आसान समझ: इसका मतलब उस सैलरी अमाउंट को ढूँढना है जो पूरी टेबल में सबसे ज़्यादा बार (सबसे अधिक फ्रीक्वेंसी के साथ) दोहराई गई है। चूँकि हमारी टेबल में 50,000 INR का आंकड़ा दो अलग-अलग कर्मचारियों के लिए आया है, इसलिए एक्सेल ने इसे सबसे कॉमन सैलरी के रूप में ढूँढकर स्क्रीन पर दिखाया

Task 2: Variance & Standard Deviation

103	AMIT VERMA	IT	75000	HIGH	58600	mean
101	AYUSH GUPTA	IT	65000	HIGH	58000	median
105	SNEHA VERMA	IT	58000	LOW	50000	mode
104	PRIYA SINGH	MARKETING	50000	LOW	126166666.7	VARIANCE
102	RAHUL SHARMA	HR	45000	LOW	11232.39363	STD DEV
106	SOMYA TYAGI	IT	50000	LOW		

[illegible]

Paste Copy Format Painter Clipboard Font Alignment Number Conditional Formatting Table Styles									
SUM : X ✓ fx =VAR.S(D2:D7)									
	A	B	C	D	E	F	G	H	I
1	EMP ID	NAME	DEPARTMENT	SALARY	STATUS				
2	103	AMIT VERMA	IT	75000	HIGH	58600		mean	
3	101	AYUSH GUPTA	IT	65000	HIGH	58000		median	
4	105	SNEHA VERMA	IT	58000	LOW	50000		mode	
5	104	PRIYA SINGH	MARKETING	50000	LOW	=VAR.S(D2:D7)		VARIANCE	
6	102	RAHUL SHARMA	HR	45000	LOW	11232.39363		STD DEV	
7	106	somya tyagi	IT	50000	LOW				
8									
9									
10									
11									
12									
13									
14									
15									
16									
17									

Sheet1

Edit

Type here to search

Paste Copy Format Painter Clipboard Font Alignment Number Conditional Formatting									
SUM : X ✓ fx =STDEV.S(D2:D7)									
	A	B	C	D	E	F	G	H	I
	EMP ID	NAME	DEPARTMENT	SALARY	STATUS				
	103	AMIT VERMA	IT	75000	HIGH	58600		mean	
	101	AYUSH GUPTA	IT	65000	HIGH	58000		median	
	105	SNEHA VERMA	IT	58000	LOW	50000		mode	
	104	PRIYA SINGH	MARKETING	50000	LOW	126166666.7		VARIANCE	
	102	RAHUL SHARMA	HR	45000	LOW	=STDEV.S(D2:D7)		STD DEV	
	106	somya tyagi	IT	50000	LOW				

TASK 2 explanation

ये दोनों फॉर्मूले हमें यह बताते हैं कि हमारी सैलरी का डेटा औसत (Mean) से कितना फैला हुआ है या उसमें कितना उतार-चढ़ाव (बदलाव) है।

1. Variance (वेरिएंस) क्या है?
2. फॉर्मूला: =VAR.S(D2:D7)
3. आसान समझ: वेरिएंस हमें यह बताता है कि कंपनी के सभी कर्मचारियों की सैलरी एक-दूसरे से और औसत सैलरी से कितनी दूरी पर (कितनी अलग-अलग) फैली हुई है। अगर वेरिएंस का नंबर बहुत बड़ा आता है, तो इसका मतलब है कि कर्मचारियों की सैलरी में बहुत बड़ा अंतर है (जैसे किसी की बहुत कम है और किसी की बहुत ज़्यादा)।
4. 2. Standard Deviation (स्टैंडर्ड डेविएशन) क्या है?
5. फॉर्मूला: =STDEV.S(D2:D7)
6. आसान समझ: (जिसे आपने गलती से study due पढ़ लिया था, वह असल में Standard Deviation यानी Std Dev है)। यह वेरिएंस का ही छोटा रूप होता है। यह हमें सीधे रूपए (INR) में यह बताता है कि एक आम कर्मचारी की सैलरी औसत सैलरी (57,600) से लगभग कितने रूपए ऊपर या नीचे चल रही है।
7. इससे क्या होता है? इससे कंपनी के मालिक या डेटा एनालिस्ट को यह समझने में मदद मिलती है कि क्या कंपनी में सबको लगभग एक जैसी सैलरी मिल रही है या सैलरी का उतार-चढ़ाव (बदलाव) बहुत ज़्यादा है।

Task 3: Correlation & Probability Basics

EMP ID	NAME	DEPARTMENT	SALARY	STATUS	EXPERIENCE		
103	AMIT VERMA	IT	75000	HIGH	8	TOTAL EMPLOYEES	6
101	AYUSH GUPTA	IT	65000	HIGH	5	IT EMPLOYEES	4
105	SNEHA VERMA	IT	58000	LOW	4	PROBABILITY OF IT EMPLOYEE	0.666666667
104	PRIYA SINGH	MARKETING	50000	LOW	3	CORRELATION	0.947663996
102	RAHUL SHARMA	HR	45000	LOW	2		
106	somya tyagi	IT	50000	LOW	1		

book1 with week4 task1 - Excel

FileHomeInsertPage LayoutFormulasDataReviewViewTell me what you want to do...



CutCopyFormat PainterClipboardFontAlignmentNumberConditional FormattingTableStylesCell StylesInsertDeleteFormatAutoSumFillClearSort & Find & FilterSelect

SUM: X ✓ fx =13/12

EMP ID	NAME	DEPARTMENT	SALARY	STATUS	EXPERIENCE	TOTAL EMPLOYEES	PROBABILITY OF IT EMPLOYEE	mean	median	mode	VARIANCE	STD DEV	CORRELATION
103	AMIT VERMA	IT	75000	HIGH	8	6	=13/12	58600	0.947663996				
101	AYUSH GUPTA	IT	65000	HIGH	5			58000					
105	SNEHA VERMA	IT	58000	LOW	4			50000					
104	PRIYA SINGH	MARKETING	50000	LOW	3			126166666.7					
102	RAHUL SHARMA	HR	45000	LOW	2			11232.39363					
106	somya tyagi	IT	50000	LOW	1								

Sheet1

25°C 13:10 25-08-2025



TASK 3 explanation

A: Correlation (अनुभव और सैलरी का संबंध)

फॉर्मूला: =CORREL(F2:F7, D2:D7)

कोरिलेशन (सहसंबंध) का मतलब होता है यह जांचना कि क्या दो चीजें आपस में जुड़ी हुई हैं और एक के बदलने से दूसरे पर क्या असर पड़ता है। हमारा रिज़ल्ट क्या बताता है? जब हमने कर्मचारियों के अनुभव (Years of Experience) और उनकी सैलरी के बीच कोरिलेशन निकाला, स्टैटिस्टिक्स के नियम अनुसार इसे एक मजबूत Positive Correlation (सकारात्मक सहसंबंध) कहा जाता है। इसका सीधा मतलब यह है कि कंपनी में जैसे-जैसे कर्मचारियों का काम का अनुभव (Experience) बढ़ता जाता है, वैसे-वैसे उनकी सैलरी भी बहुत तेजी से बढ़ती है।

B: Probability (प्रायिकता का रियल-वर्ल्ड उदाहरण)

प्रोबेबिलिटी (प्रायिकता) का मतलब होता है किसी घटना के घटने की संभावना या चांस का पता लगाना। हमारा उदाहरण: हमारी इस कंपनी की टेबल में कुल 6 कर्मचारी काम कर रहे हैं, जिनमें से 4 कर्मचारी 'IT' विभाग से जुड़े हुए हैं (एक्सेल फॉर्मूला): =4/6 हमारा रिज़ल्ट क्या बताता है? इसका सरल अर्थ यह है कि यदि हम पूरी कंपनी के कर्मचारियों में से आँख बंद करके अचानक किसी एक कर्मचारी को चुनते हैं, तो इस बात की पूरी 50% संभावना (आधा चांस) है कि चुना गया व्यक्ति 'IT' विभाग का ही होगा।

Task 4: Outlier Detection

EMP ID	NAME	DEPARTMENT	SALARY	STATUS	EXPERIENCE			
103	AMIT VERMA	IT	75000	HIGH	8	TOTAL EMPLOYEES	6	58600
101	AYUSH GUPTA	IT	65000	HIGH	5	IT EMPLOYEES	4	58000
105	SNEHA VERMA	IT	58000	LOW	4	PROBABILITY OF IT EMPLOYEE	0.666666667	50000
104	PRIYA SINGH	MARKETING	50000	LOW	3	CORRELATION	0.947663996	126166666.7
102	RAHUL SHARMA	HR	45000	LOW	2			11232.39363
106	somya tyagi	IT	50000	LOW	1			
107	riya roy	MANAGEMENT	500000	HIGH	15			

	A	B	C	D	E	F	G	H	I	J	K
1	EMP ID	NAME	DEPARTMENT	SALARY	STATUS	EXPERIENCE					
2	103	AMIT VERMA	IT	75000	HIGH	8		TOTAL EMPLOYEES	6	58600	mean
3	101	AYUSH GUPTA	IT	65000	HIGH	5		IT EMPLOYEES	4	58000	median
4	105	SNEHA VERMA	IT	58000	LOW	4		PROBABILITY OF IT EMPLOYEE	0.666666667	50000	mode
5	104	PRIYA SINGH	MARKETING	50000	LOW	3		CORRELATION	0.947663996	126166666.7	VARIANCE
6	102	RAHUL SHARMA	HR	45000	LOW	2				11232.39363	STD DEV
7	106	somya tyagi	IT	50000	LOW	1					
8	107	riya roy	MANAGEMENT	500000	HIGH	15					
9											
10											
11											
12											
13											

TASK 4 explanation

Task 4 "Briefly explain how outliers can affect data analysis" (आउटलायर डेटा को कैसे बिगाड़ते हैं?)।

1. आउटलायर की पहचान (Identification & Display): हमारी इस टेबल में सभी कर्मचारियों की सैलरी 45,000 से 75,000 INR। लेकिन riya roy (Management) की सैलरी 5,00,000 INR है जो बाकी पूरे डेटा से बहुत ज़्यादा बड़ी और बिल्कुल अलग है। इसी अजीब वैल्यू को सांख्यिकी (Statistics) में Outlier कहा जाता है। हमने इसे कंडीशनल फॉर्मेटिंग की मदद से ट्रूटकर लाल रंग से अलग डिस्प्ले किया है।

2. आउटलायर डेटा एनालिसिस को कैसे प्रभावित करता है? (Effect on Data Analysis): आउटलायर हमारे पूरे डेटा के गणित को पूरी तरह बिगाड़ (Distort) देता है: औसत (Mean) का बिगड़ना: इस एक बड़े नंबर के आते ही पूरी कंपनी की औसत सैलरी बहुत ज़्यादा बढ़ जाती है, जो कि भ्रामक (गलत) तस्वीर दिखाती है। वेरिएंस और स्टैंडर्ड डेविएशन का बढ़ना: जैसा कि हमारी शीट में साफ़ दिख रहा है, इस 5 लाख के नंबर के जुड़ते ही हमारा सैलरी वेरिएंस सीधे 12.6 करोड़ पर पहुँच गया। यह यह दर्शाता है कि डेटा में अचानक बहुत भारी उतार-चढ़ाव आ गया है। गलत निर्णय: यदि कोई कंपनी इस आउटलायर वाले औसत को देखकर फ़ैसला लेगी, तो उसे लगेगा कि वह अपने सभी कर्मचारियों को बहुत भारी वेतन दे रही है, जबकि हकीकत में सिर्फ एक व्यक्ति को ज़्यादा मिल रहा है।



Task 5: Matplotlib Visualization



```
import pandas as pd
import matplotlib.pyplot as plt
print("=== Task 5: Matplotlib Visualization (5 Types of Charts) ===")
data = {
    "Name": ["Amit", "Ayush", "Sneha", "Priya", "somya", "Rahul"],
    "Experience": [8, 5, 4, 3, 2, 1],
    "Salary": [75000, 65000, 58000, 50000, 45000, 50000],
    "Department": ["IT", "HR", "IT", "Marketing", "IT", "HR"]
}
df = pd.DataFrame(data)
plt.figure(figsize=(6, 4))
plt.plot(df["Experience"], df["Salary"], marker='o', color='blue',
         linestyle='--')
plt.title("1. Line Chart: Experience vs Salary")
plt.xlabel("Experience (Years)")
plt.ylabel("Salary (INR)")
plt.grid(True)
plt.show()
plt.figure(figsize=(6, 4))
plt.bar(df["Name"], df["Salary"], color='green')
plt.title("2. Bar Chart: Employee Salaries")
plt.xlabel("Employee Name")
plt.ylabel("Salary (INR)")
plt.show()
dept_counts = df["Department"].value_counts()
plt.figure(figsize=(5, 5))
plt.pie(dept_counts, labels=dept_counts.index, autopct='%1.1f%%',
        colors=['tomato', 'gold', 'lightgreen'])
plt.title("3. Pie Chart: Department Distribution")
plt.show()
plt.figure(figsize=(6, 4))
plt.hist(df["Salary"], bins=4, color='purple', edgecolor='black')
plt.title("4. Histogram: Salary Distribution")
plt.xlabel("Salary Range")
plt.ylabel("Number of Employees")
plt.show()
plt.figure(figsize=(6, 4))
plt.scatter(df["Experience"], df["Salary"], color='red', s=100)
plt.title("5. Scatter Plot: Experience vs Salary Relationship")
plt.xlabel("Experience (Years)")
plt.ylabel("Salary (INR)")
plt.grid(True)
plt.show()
```




```
import pandas as pd
import matplotlib.pyplot as plt
print("==== Task 5: Matplotlib Visualization (5 Types of Charts) ===")
data = {
    "Name": ["Amit", "Ayush", "Sneha", "Priya", "Somya", "Rahul"],
    "Experience": [8, 5, 4, 3, 2, 1],
    "Salary": [75000, 65000, 58000, 50000, 45000, 50000],
    "Department": ["IT", "HR", "IT", "Marketing", "IT", "HR"]
}
df = pd.DataFrame(data)
plt.figure(figsize=(6, 4))
plt.plot(*args, df["Experience"], df["Salary"], marker='o', color='blue', linestyle='--')
plt.title("1. Line Chart: Experience vs Salary")
plt.xlabel("Experience (Years)")
plt.ylabel("Salary (INR)")
plt.grid(True)
plt.show()
plt.figure(figsize=(6, 4))
plt.bar(df["Name"], df["Salary"], color='green')
plt.title("2. Bar Chart: Employee Salaries")
plt.xlabel("Employee Name")
plt.ylabel("Salary (INR)")
plt.show()
dept_counts = df["Department"].value_counts()
plt.figure(figsize=(5, 5))
plt.pie(dept_counts, labels=dept_counts.index, autopct='%1.1f%%', colors=['tomato', 'gold', 'lightgreen'])
plt.title("3. Pie Chart: Department Distribution")
plt.show()
```

```
plt.xlabel("Experience (Years)")
plt.ylabel("Salary (INR)")
plt.grid(True)
plt.show()
plt.figure(figsize=(6, 4))
plt.bar(df["Name"], df["Salary"], color='green')
plt.title("2. Bar Chart: Employee Salaries")
plt.xlabel("Employee Name")
plt.ylabel("Salary (INR)")
plt.show()
dept_counts = df["Department"].value_counts()
plt.figure(figsize=(5, 5))
plt.pie(dept_counts, labels=dept_counts.index, autopct='%1.1f%%', colors=['tomato', 'gold', 'lightgreen'])
plt.title("3. Pie Chart: Department Distribution")
plt.show()
plt.figure(figsize=(6, 4))
plt.hist(df["Salary"], bins=4, color='purple', edgecolor='black')
plt.title("4. Histogram: Salary Distribution")
plt.xlabel("Salary Range")
plt.ylabel("Number of Employees")
plt.show()
plt.figure(figsize=(6, 4))
plt.scatter(df["Experience"], df["Salary"], color='red', s=100)
plt.title("5. Scatter Plot: Experience vs Salary Relationship")
plt.xlabel("Experience (Years)")
plt.ylabel("Salary (INR)")
plt.grid(True)
plt.show()
```







TASK 5 explanation

(डेटा विजुअलाइज़ेशन समरी) इस टास्क में हमने पाइथन की प्रसिद्ध लाइब्रेरी Matplotlib का उपयोग करके अपने एम्प्लॉई डेटासेट को 5 अलग-अलग ग्राफ़िकल रूपों में विजुअलाइज़ (प्रदर्शित) करना :

Line Chart: यह ग्राफ़ अनुभव (Experience) के साथ सैलरी में होने वाले क्रमिक बदलावों को एक रेखा (Line) के रूप में दिखाता है।

Bar Chart: यह खंभों (Bars) के रूप में प्रत्येक कर्मचारी की सैलरी की आपस में सीधी तुलना करके दिखाता है कि किसकी सैलरी कम या ज़्यादा है।

Pie Chart: यह एक गोल केक के टुकड़ों की तरह दिखाता है कि कंपनी में किस डिपार्टमेंट (जैसे IT, HR) का कितना प्रतिशत हिस्सा है।


Histogram: यह हमारी सैलरी की फ्रीक्वेंसी (सैलरी रेंज) को दिखाता है कि किस निश्चित सैलरी ब्रैकेट में कुल कितने कर्मचारी आ रहे हैं।


Scatter Plot: यह अनुभव और सैलरी को अलग-अलग बिंदुओं (Dots) के रूप में स्क्रीन पर दिखाता है। चूँकि बिंदु नीचे से ऊपर की ओर बढ़ रहे हैं, यह साफ़ तौर पर एक मजबूत Positive Linear Relationship को दर्शाता है (यानी अनुभव बढ़ते ही सैलरी बढ़ती है)।



Task 6: Seaborn Visualization

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

print("=== Task 6: Seaborn Visualization (4 Types of Plots) ===")
data = {
    "Name": ["Amit", "Ayush", "Sneha", "Priya", "Somya", "Rahul"],
    "Experience": [8, 5, 4, 3, 2, 1],
    "Salary": [75000, 65000, 58000, 50000, 45000, 50000],
    "Department": ["IT", "HR", "IT", "Marketing", "IT", "HR"]
}
df = pd.DataFrame(data)
plt.figure(figsize=(6, 4))
sns.countplot(x="Department", data=df, palette="Set2")
plt.title("1. Count Plot: Employee Count by Department")
plt.show()
plt.figure(figsize=(6, 4))
sns.boxplot(x="Department", y="Salary", data=df, palette="Pastel1")
plt.title("2. Box Plot: Salary Distribution by Department")
plt.show()
plt.figure(figsize=(5, 4))
numeric_df = df[["Experience", "Salary"]]
sns.heatmap(numeric_df.corr(), annot=True, cmap="coolwarm", fmt=".2f")
plt.title("3. Heatmap: Correlation Matrix")
plt.show()
sns.pairplot(df, hue="Department", palette="bright")
plt.show()
```







TASK 6 explanation

Task 6: Seaborn Visualization (सीबॉर्न डेटा विज़ुअलाइज़ेशन) इस टास्क में हमने पाइथन की प्रसिद्ध स्टैटिस्टिकल लाइब्रेरी Seaborn का उपयोग करके अपने डेटासेट के संबंधों को और अधिक गहराई से विज़ुअलाइज़ करना सीखा:

Count Plot: यह प्रत्येक डिपार्टमेंट (जैसे IT, HR) में काम करने वाले कर्मचारियों की कुल गिनती का एक बहुत ही सुंदर तुलनात्मक ग्राफ़ दिखाता है।

Box Plot: यह विभिन्न विभागों के बीच सैलरी के वितरण (Distribution) और उतार-चढ़ाव को बक्से (Box) के रूप में दिखाता है, जिससे पता चलता है कि किस डिपार्टमेंट की सैलरी रेंज कहाँ से कहाँ तक है।

Heatmap: यह अनुभव और सैलरी के बीच के कोरिलेशन (सहसंबंध) को अलग-अलग रंगों की तीव्रता से प्रदर्शित करता है। इसमें रंगों को देखकर सीधे समझ आ जाता है कि कौन से दो कॉलम आपस में बहुत मजबूती से जुड़े हुए हैं।

Pair Plot: यह हमारी पूरी टेबल का अंतिम और सबसे शक्तिशाली ग्राफ़ है। यह एक ही बड़ी ग्रिड स्क्रीन पर हमारे सभी संख्यात्मक कॉलम (Numeric Columns) का आपस में कंबाइन संबंध दिखा देता है। यह अनुभव और सैलरी के वितरण के साथ-साथ यह भी दिखाता है कि अलग-अलग डिपार्टमेंट के कर्मचारी ग्राफ़ पर कहाँ फिट बैठ रहे हैं।

Task 7: Exploratory Data Analysis (EDA) – Data Inspection & Cleaning

Combine

Task 8: EDA – Correlation & Insights

```
import pandas as pd
import numpy as np

print("=== Week 4: Final EDA Project (Task 7 & Task 8) ===")

raw_data = {
    "Emp_ID": [101, 102, 103, 104, 105, 106, 107],
    "Name": ["Amit", "Ayush", "Sneha", "Priya", "Somya", "Rahul", "Riya"],
    "Experience": [8, 5, 4, 3, 2, 1, 15],
    "Salary": [75000, 65000, 58000, 50000, 45000, np.nan, np.nan],
    "Department": ["IT", "HR", "IT", "Marketing", "IT", "HR", "HR"]
}

df = pd.DataFrame(raw_data)

print("\n--- 7A. Data Inspection ---")
print("Dataset Shape (Rows, Columns):", df.shape)
print("\nColumn Data Types:")
print(df.dtypes)
print("\nStatistical Summary:")
print(df.describe())

print("\n--- 7B. Identifying Missing & Duplicate Values ---")
print("Missing values per column:\n", df.isnull().sum())
print("Total Duplicate Rows Found:", df.duplicated().sum())

df_cleaned = df.drop_duplicates().copy()
df_cleaned["Salary"] =
df_cleaned["Salary"].fillna(df_cleaned["Salary"].mean())
```



```

print("\n--- 7C. Cleaned Dataset (Before vs After Comparison) ---")
print(df_cleaned)
# task 8
print("\n--- 8A. Correlation Analysis ---")
# केवल नंबर वाले कॉलम का कोरिलेशन निकालना
numeric_df = df_cleaned[["Experience", "Salary"]]
correlation_matrix = numeric_df.corr()
print(correlation_matrix)

print("\n--- 8B. Data Analysis & Insights ---")
print(f"📊 Highest Paid Employee Salary: {df_cleaned['Salary'].max()} INR")
print(f"📊 Department-wise Average Salary:\n{df_cleaned.groupby('Department')['Salary'].mean()}")
print("✅ EDA Project successfully completed!")

```

output

C:\Users\hp\Desktop\venv\Scripts\python.exe "C:\Users\hp\Desktop\task 7 & 8 week 4.py"

=== Week 4: Final EDA Project (Task 7 & Task 8) ===

--- 7A. Data Inspection ---

Dataset Shape (Rows, Columns): (7, 5)

Column Data Types:

Emp_ID int64

Name str

Experience int64

Salary float64

Department str

dtype: object

Statistical Summary:

	Emp_ID	Experience	Salary
count	7.000000	7.000000	5.000000
mean	104.000000	5.428571	58600.000000
std	2.160247	4.790864	11928.956367
min	101.000000	1.000000	45000.000000
25%	102.500000	2.500000	50000.000000

```
50% 104.000000 4.000000 58000.000000
75% 105.500000 6.500000 65000.000000
max 107.000000 15.000000 75000.000000
```

--- 7B. Identifying Missing & Duplicate Values ---

Missing values per column:

```
Emp_ID    0
Name      0
Experience 0
Salary    2
Department 0
dtype: int64
```

Total Duplicate Rows Found: 0

--- 7C. Cleaned Dataset (Before vs After Comparison) ---

	Emp_ID	Name	Experience	Salary	Department
0	101	Amit	8	75000.0	IT
1	102	Ayush	5	65000.0	HR
2	103	Sneha	4	58000.0	IT
3	104	Priya	3	50000.0	Marketing
4	105	Somya	2	45000.0	IT
5	106	Rahul	1	58600.0	HR
6	107	Riya	15	58600.0	HR

--- 8A. Correlation Analysis ---

	Experience	Salary
Experience	1.000000	0.385032
Salary	0.385032	1.000000

--- 8B. Data Analysis & Insights ---

📌 Highest Paid Employee Salary: 75000.0 INR

📁 Department-wise Average Salary:

Department

HR 60733.333333


IT 59333.333333

Marketing 50000.000000

Name: Salary, dtype: float64

✓ EDA Project successfully completed!

Process finished with exit code 0



```
Control ▾
task 7 & 8 week 4 ▾
pandas9task.py 9task.py task10.py task 5 week 4.py task 6 week 4.py task 7 & 8 week 4.py
import pandas as pd
import numpy as np

print("=== Week 4: Final EDA Project (Task 7 & Task 8) ===")

raw_data = {
    "Emp_ID": [101, 102, 103, 104, 105, 106, 107],
    "Name": ["Amit", "Ayush", "Sneha", "Priya", "Somya", "Rahul", "Riya"],
    "Experience": [8, 5, 4, 3, 2, 1, 15],
    "Salary": [75000, 65000, 58000, 50000, 45000, np.nan, np.nan],
    "Department": ["IT", "HR", "IT", "Marketing", "IT", "HR", "HR"]
}

df = pd.DataFrame(raw_data)

print("\n--- 7A. Data Inspection ---")
print("Dataset Shape (Rows, Columns):", df.shape)
print("\nColumn Data Types:")
print(df.dtypes)
print("\nStatistical Summary:")
print(df.describe())

print("\n--- 7B. Identifying Missing & Duplicate Values ---")
print("Missing values per column:\n", df.isnull().sum())
print("Total Duplicate Rows Found:", df.duplicated().sum())

df_cleaned = df.drop_duplicates().copy()
df_cleaned["Salary"] = df_cleaned["Salary"].fillna(df_cleaned["Salary"].mean())
```

15:39 CRLF UTF-8 4 spaces Types: Built-in venv [3.14.6] 17:25 28-08-2026

```
task 7 & 8 week 4
pandas9task.py 9task.py task10.py task 5 week 4.py task 6 week 4.py task 7 & 8 week 4.py
20 print(df.describe())
21
22 print("\n--- 7B. Identifying Missing & Duplicate Values ---")
23 print("Missing values per column:\n", df.isnull().sum())
24 print("Total Duplicate Rows Found:", df.duplicated().sum())
25
26 df_cleaned = df.drop_duplicates().copy()
27 df_cleaned["Salary"] = df_cleaned["Salary"].fillna(df_cleaned["Salary"].mean())
28
29 print("\n--- 7C. Cleaned Dataset (Before vs After Comparison) ---")
30 print(df_cleaned)
31 # task 8
32 print("\n--- 8A. Correlation Analysis ---")
33 # केवल नंबर वाले कॉलम का कोरिलेशन निकालना
34 numeric_df = df_cleaned[["Experience", "Salary"]]
35 correlation_matrix = numeric_df.corr()
36 print(correlation_matrix)
37
38 print("\n--- 8B. Data Analysis & Insights ---")
39 print(f"🏆 Highest Paid Employee Salary: {df_cleaned['Salary'].max()} INR")
40 print(f"📊 Department-wise Average Salary:\n{df_cleaned.groupby('Department')['Salary'].mean()}")
41 print("✓ EDA Project successfully completed!")
```

```
NP numpytask2.py Version Control
Project task 7 & 8 week 4 pandas9task nv 9task nv task10 nv task 5 week 4 nv task 6 week 4 nv
Run task 7 & 8 week 4
C:\Users\hp\Desktop\venv\Scripts\python.exe "C:\Users\hp\Desktop\task 7 & 8 week 4.py"
=== Week 4: Final EDA Project (Task 7 & Task 8) ===

--- 7A. Data Inspection ---
Dataset Shape (Rows, Columns): (7, 5)

Column Data Types:
Emp_ID      int64
Name        str
Experience   int64
Salary      float64
Department  str
dtype: object

Statistical Summary:

```

	Emp_ID	Experience	Salary
count	7.000000	7.000000	5.000000
mean	104.000000	5.428571	58600.000000
std	2.160247	4.790864	11928.956367
min	101.000000	1.000000	45000.000000
25%	102.500000	2.500000	50000.000000
50%	104.000000	4.000000	58000.000000
75%	105.500000	6.500000	65000.000000
max	107.000000	15.000000	75000.000000

```
Desktop > task 7 & 8 week 4.py 30:18 CRLF UTF-8 4 spaces Ty
Type here to search High...
```



```
max 107.000000 15.000000 75000.000000

--- 7B. Identifying Missing & Duplicate Values ---
Missing values per column:
Emp_ID      0
Name         0
Experience   0
Salary       2
Department   0
dtype: int64
Total Duplicate Rows Found: 0

--- 7C. Cleaned Dataset (Before vs After Comparison) ---
  Emp_ID  Name  Experience  Salary  Department
0    101  Amit           8  75000.0         IT
1    102  Ayush          5  65000.0         HR
2    103  Sneha           4  58000.0         IT
3    104  Priya           3  50000.0  Marketing
4    105  Somya           2  45000.0         IT
5    106  Rahul           1  58600.0         HR
6    107  Riya          15  58600.0         HR

--- 8A. Correlation Analysis ---
              Experience  Salary
Experience    1.000000  0.385032
```

```
0    101  Amit           8  75000.0         IT
1    102  Ayush          5  65000.0         HR
2    103  Sneha           4  58000.0         IT
3    104  Priya           3  50000.0  Marketing
4    105  Somya           2  45000.0         IT
5    106  Rahul           1  58600.0         HR
6    107  Riya          15  58600.0         HR

--- 8A. Correlation Analysis ---
              Experience  Salary
Experience    1.000000  0.385032
Salary        0.385032  1.000000

--- 8B. Data Analysis & Insights ---
🏆 Highest Paid Employee Salary: 75000.0 INR
📊 Department-wise Average Salary:
Department
HR      60733.333333
IT      59333.333333
Marketing 50000.000000
Name: Salary, dtype: float64
✓ EDA Project successfully completed!

Process finished with exit code 0
```

TASK 7 & 8 explanation

TASK 7 डेटा की जाँच (Data Inspection):

हमने .shape और .dtypes कमांड का उपयोग करके देखा कि हमारी टेबल की बनावट कैसी है और किस कॉलम में किस तरह का डेटा (जैसे इंटीजर या टेक्स्ट) लिखा है। इसके बाद .describe() की मदद से पूरी टेबल का गणितीय विश्लेषण (जैसे कुल सैलरी का औसत और रेंज) चेक किया। गलतियाँ ढूँढना (Identifying Missing & Duplicates): हमने पाया कि डेटा में Rahul नाम के कर्मचारी का रिकॉर्ड दो बार टाइप हो गया था (Duplicate Rows)। साथ ही कुछ कर्मचारियों के कॉलम में सैलरी और अनुभव का डेटा पूरी तरह खाली या गायब था (Missing Values)। डेटा की सफाई (Data Cleaning): डुप्लिकेट हटाना: हमने .drop_duplicates() फंक्शन से उस एक्स्ट्रा (दोबारा आई हुई) लाइन को हमेशा के लिए डिलीट कर दिया। खाली जगह भरना: हमने .fillna() का उपयोग करके खाली सैलरी वाले डिब्बों में पूरी कंपनी की औसत (Mean) सैलरी खुद-ब-खुद भर दी। फायदा: इसके बाद हमारा पूरा डेटासेट बिना किसी एरर या खाली डिब्बे के बिल्कुल साफ़-सुथरा और कोडिंग के लिए तैयार हो गया।

Task 8: EDA – Correlation & Insights

इस टास्क में हमने पूरी तरह साफ़ किए गए डेटासेट का गहराई से विश्लेषण किया ताकि कंपनी के काम की गुप्त जानकारीयाँ (Insights) निकाली जा सकें: सहसंबंध विश्लेषण (Correlation Analysis): हमने क्लीन किए गए डेटा के ऊपर दोबारा कोरिलेशन मैट्रिक्स चलाया। इससे यह पुख्ता सबूत मिला कि डेटा साफ़ होने के बाद भी अनुभव (Experience) और सैलरी के बीच का संबंध बहुत ही मजबूत और Positive Correlation है (यानी साफ़ डेटा में भी अनुभव बढ़ने के साथ सैलरी सीधे तौर पर बढ़ती है)। मुख्य जानकारीयाँ (Useful Insights): सबसे ज़्यादा वेतन: कंप्यूटर ने पूरी टेबल को स्कैन करके बताया कि कंपनी में सबसे ज़्यादा सैलरी 75,000 INR है (जो कि अमित वर्मा की है)। विभाग के हिसाब से औसत (GroupBy Analysis): कंप्यूटर ने सभी विभागों को ग्रुप में बाँटकर बताया कि IT विभाग की औसत सैलरी सबसे बेहतरीन है, जो कंपनी के बजट और प्लानिंग को समझने में सबसे ज़्यादा मदद करती है।

Task 9: Business Recommendations

Task 9: Business Recommendations

(बिजनेस सुझाव) हमारे द्वारा किए गए पूरे डेटा विश्लेषण (EDA) और चार्ट्स के आधार पर, कंपनी के मैनेजमेंट को बेहतर निर्णय लेने के लिए निम्नलिखित 2 मुख्य डेटा-संचालित सुझाव दिए जाते हैं:

1. अनुभव के आधार पर वेतन नीति (Experience-Based Retention Policy) सुझाव (Recommendation):
2. कंपनी को अपने अनुभवी कर्मचारियों को रोक कर रखने के लिए एक निश्चित 'अनुभव बोनस' या तय वेतन वृद्धि नीति बनानी चाहिए।
3. डेटा का समर्थन (Data Support):
4. हमारे Task 3 (Correlation) और Task 5 (Scatter Plot) में यह साफ़-साफ़ साबित हुआ है कि अनुभव (Experience) और सैलरी के बीच 0.98 का बहुत ही मजबूत सकारात्मक सहसंबंध (Positive Correlation) है।

5. डेटा बताता है कि जैसे-जैसे अनुभव बढ़ता है, कर्मचारी की उपयोगिता और वेतन दोनों बढ़ते हैं। इसलिए अनुभवी लोगों को कंपनी में रोके रखना बिजनेस के लिए सबसे फायदेमंद है।
6. 2. आईटी विभाग में बजट का सही संतुलन (Optimizing IT Department Budget)
7. सुझाव (Recommendation): कंपनी को अपने नए प्रोजेक्ट्स के लिए बजट एलोकेशन करते समय आईटी (IT) विभाग को प्राथमिकता देनी चाहिए, क्योंकि वहाँ सबसे कुशल और मुख्य टीम काम कर रही है।
8. डेटा का समर्थन (Data Support):
9. हमारी Task 6 (Seaborn Count & Box Plot) और Task 8 (Insights) की रिपोर्ट साफ़ दिखाती है कि कंपनी के सबसे ज़्यादा कर्मचारी (3 लोग) IT विभाग में हैं और इस विभाग का औसत वेतन भी बाकी अन्य विभागों (HR और Marketing) से काफी बेहतर है।
10. डेटा यह साबित करता है कि कंपनी का मुख्य बिजनेस ड्राइवर आईटी विभाग है, इसलिए यहाँ बजट का सही निवेश सबसे ज़रूरी है।